

# 1. Введение

## Зачем этот раздел

Сначала мы представим краткие определения ключевых ставок и метрик для более прозрачной методологии. Это позволит уточнить, какие именно величины мы намерены прогнозировать и какие критерии точности будут использованы. Вслед за этим будет изложена мотивация прогнозирования ruonia и возможный спектр методов.

### 1.1. Словарь ключевых понятий

**RUONIA**<sup>1</sup> — средневзвешенная ставка по необеспеченным межбанковским займам на один день (*overnight*). Банк России собирает сделки, считает взвешенное среднее и публикует его на следующий рабочий день. Это единственный публичный индикатор того, «сколько сейчас действительно стоит рубль на межбанковском рынке».

**Овернайт-ставки ARR:** SOFR (США), SONIA (Британия), €STR (Евро) появились после отказа от LIBOR в 2021г. [2]. Их объединяет ежедневная публикация и использование как базовой ставки по деривативам.

**Базис-пойнт (bp)** — одна сотая процента,  $1 \text{ bp} = 0.01\%$ .

**Волатильность** —

$$\sigma_t^2 = \text{Var}(\Delta r_{t+1} \mid \mathcal{F}_t)$$

где  $\mathcal{F}_t$  — «всё, что мы знаем сегодня»: прошлые значения RUONIA, ключевой ставки, курс USD/RUB, индексы ликвидности и т.д. Может браться также стандартное отклонение или логарифм стандартного отклонения.

**VaR<sub>99</sub>** — такое  $q$ , что однодневный убыток портфеля превысит  $q$  не чаще 1 % случаев. Регулятор требует бэкtest на последних 250 дней и штрафует, если нарушений слишком много [3].

---

<sup>1</sup>Russian Overnight Index Average. Методика — [1].

## 1.2. Почему прогноз RUONIA интересен для ML

Точность прогноза overnight-ставки на  $\pm 5$  bp уже экономит сотни тысяч долларов в день на портфеле  $1 \times 10^9$  RUB O/N-свопов [4]. В России для прогнозирования RUONIA традиционно применяют сочетание:

- **Модель Васичека:** однопараметрическое СДУ

$$dr_t = \kappa(\theta - r_t) dt + \sigma dW_t,$$

где  $\kappa$  — скорость возврата к среднему  $\theta$ ,  $\sigma$  — амплитуда случайных флуктуаций,  $W_t$  — винеровский процесс. Оно даёт явную формулу для условного среднего  $\mathbb{E}[r_{t+h} | \mathcal{F}_t] = \theta + (r_t - \theta)e^{-\kappa h}$ , но не оценивает распределение и реагирует на шоки плавно.

- **EWMA-волатильность:** экспоненциально взвешенная скользящая оценка дисперсии

$$\sigma_t^2 = \lambda \sigma_{t-1}^2 + (1 - \lambda) (r_t - r_{t-1})^2, \quad \lambda \in (0, 1).$$

В стандарте Basel II обычно берут  $\lambda = 0.94$ . Метод прост в реализации, но «запаздывает» при резких изменениях: крупный скачок волатильности долго «расплывается» по окну.

Эти подходы дают только точечный прогноз среднего и сглаженную волатильность, но слабо реагируют на внезапные изменения колебаний, к примеру, после неожиданных заявлений Центробанка, что снижает точность оценки рисков.

## 1.3. Актуальные результаты и мотивация

За последние два года вышла серия статей, показывающих, что *вероятностные* и *генеративные* модели задают новый бенчмарк для прогнозов о/n-ставок (SOFR, €STR, SONIA):

- **DeepAR / DeepState.** Выигрыш до 25 % по CRPS и Pinball-loss против ARIMA для SOFR [5].

- **TFT + Quantile Loss.** Интервалы 5–95 %, стресс-сценарии [6, 7].
- **Normalizing Flows & Diffusion Models.** Улучшение VaR (99 %) на 30 % относительно GARCH [8—10].
- **Bayesian non-parametrics.** Гибкая аппроксимация условной плотности без заданного семейства [11].
- **Quantile Regression Forests & GNN.** Дешёвые в обучении распределённые прогнозы и учёт сетевой структуры рынков [12, 13].
- **Large-Language / Multimodal models.** Учёт новостей ФРС и текстовых факторов снижает ES-backtest [14—16].

Для ruonia подобного анализа нет. Мы хотим построить *полное* распределение  $P(r_{t+h} \mid \mathcal{F}_t)$  и проверить, насколько современные глубокие модели (TFT, DeepAR, NF, Diffusion, GNN) превосходят базовый подход «Васичек + EWMA». Долгосрочная цель — Neural SDE / Neural PDE: обучить дифференциальное уравнение, объясняющее «длинную память» RUONIA.

## 2. Цели и задачи

1. **RQ1:** Улучшают ли TFT, DeepAR, Normalizing Flows и Diffusion-TimeGrad качество *полного* прогноза (CRPS, Energy, Pinball) на горизонтах  $h \in \{1, 7, 30, 180, 365\}$  по сравнению с базовой связкой «Васичек + EWMA»?
2. **RQ2:** Снижают ли продвинутое модели волатильности (GARCH-GJR, GAS, EGARCH, Bayesian SV) частоту нарушений 99 % VaR и Expected Shortfall относительно фильтра EWMA ( $\lambda = 0.94$ )?
3. **RQ3(\*) :** Может ли *совместное* генеративное решение — Conditional NF или Neural SDE — предоставить согласованную многогоризонтную плотность  $\{r_{t+h}\}_h$  и тем самым улучшить back-тест ES? <sup>2</sup>

---

<sup>2</sup>Эта задача рассматривается как «задача со звёздочкой»: её планируется детально развернуть уже в рамках магистерского тезиса, после отработки основной части моделирования.

Наша цель — получить устойчивое распределение  $P(r_{t+h} \mid \mathcal{F}_t)$  для  $h \in \{1, 7, 30, 180, 365\}$  и тем самым закрыть пробел между «точечным» прогнозом ставки и реальными требованиями риск-менеджмента.

## 3. Методология

### 3.1. Probabilistic Sequence Models

- **Baseline (ARIMA + Vasicek + EWMA).** ARIMA( $p, d, q$ ) обеспечивает минимально-адекватную авто-коррекционную структуру; Васичек даёт экономически интерпретируемый параметр  $\kappa$ ; EWMA( $\lambda=0.94$ ) — промышленный стандарт Банка России, поэтому служит референсом.
- **DeepAR / DeepState.** (Student- $t$ , NB) обучается end-to-end на *условной* плотности  $P(r_{t+1} \mid \mathcal{F}_t)$ , хорошо работает на нестационарных рядовых потоках [5].
- **Temporal Fusion Transformer (TFT).** Комбинирует attention + gating; quantile-loss  $L_\tau$  сразу выдаёт набор доверительных интервалов, а MC-dropout калибрует неопределённость [6, 7].
- **Normalizing Flows (MAF / NSF).** Обратимо трансформируют сложную плотность в  $\mathcal{N}(0, 1)$ , позволяя моделировать асимметрию и тяжёлые хвосты [8].
- **Diffusion (TimeGrad).** Обучаем «шум  $\rightarrow$  ряд», получаем мульти-шаговые сценарии без ошибки накопления [9].
- **LLM + Time-mix.** ФРС, макро-факторы и исторический ряд объединяются в единую эмбединг-матрицу, что улучшает tails / ES прогноза [14, 16].

## 3.2. Volatility & Density Models

- **GARCH / EGARCH / GJR.** Захватывают кластеризацию волатильности; сравниваем Normal и  $t$ -шоки.
- **GAS (Generalised AR Score).** Обновляет  $\sigma_t^2$  градиентом log-likelihood, поэтому быстрее реагирует на рыночные шоки [17].
- **Bayesian SV.** MCMC NUTS даёт постериор на  $\sigma_t$ , что нужно для full-Bayes ES / VaR [11].

## 3.3. Evaluation

- *Point:* **MAE, RMSE** – привычные банковские KPI для одной цифры.
- *Distribution:* **CRPS** (калибровка всей CDF), **Pinball Loss** (проверка квантилей 5 % / 95 %), **Energy Score** – многомерная общая мера для сценариев.
- *Risk:* **VaR<sub>99</sub>, ES<sub>97.5</sub>** + Купиц, Кристофферсен – регуляторные back-тесты (Базель IV).
- *Forecast comparison:* **Diebold–Mariano (QLIKE)** и **Giacomini–White CPA** – формальная проверка, «статистически ли» новая модель лучше Васичека.

## 4. Timeline

Дата	Этап	Ключевые deliverables
17 мая	<b>W0</b>	✓ сбор данных (RUONIA, макро, рынки) ✓ первичный EDA-ноутбук (статистика, графики)
18–24 мая	<b>W1</b>	Обзор литературы и Baseline: ARIMA, Васичек, EWMA; расчёт MAE/RMSE для $h = \{1, 7, 30\}$
25–31 мая	<b>W2</b>	DeepAR & TFT (1-шаговый forecast), валидация CRPS/Pinball, первый сравнительный график
1–7 июня	<b>W3</b>	Normalizing Flows (MAF/NSF) + Diffusion TimeGrad; multi-horizon density, Energy Score
8–14 июня	<b>W4</b>	Volatility block: GARCH-GJR, GAS, Bayesian SV; VaR <sub>99</sub> /ES <sub>97.5</sub> back-тест, Купиц/Кристофферсен
15–21 июня	<b>W5</b>	Итоговые метрики + Diebold–Mariano, CPA-тесты; абляция признаков, SHAP-анализ TFT
22–28 июня	<b>W6</b>	Черновик отчёта, README для GitHub; слайды (10 стр.) для внутренней защиты
29–30 июня	<b>Buffer</b>	Полировка кода, оформление библиографии, загрузка финального PDF и ноутбуков

Задача со звёздочкой (*Neural SDE для совместного распределения*) планируется как расширение магистерского проекта: старт в июле 2025 после фиксации базовых результатов.

## Список литературы

- [1] Банк России. *Методика расчёта средней процентной ставки RUONIA*. <https://cbr.ru>. 2024.
- [2] ARRC. *ARRC Progress Report: Transition from LIBOR*. <https://www.newyorkfed.org/arrc>. 2021.
- [3] BCBS. *Basel III.2: Market Risk Framework*. <https://bis.org>. 2023.
- [4] D. Duffie и A. Yang. "Overnight Benchmark Rates: Market Impact and Forecastability". В: *Journal of Financial Markets* (2023).
- [5] David Salinas и др. "DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks". В: *International Journal of Forecasting* 36.3 (2020), с. 1181—1191. doi: 10.1016/j.ijforecast.2019.07.001.
- [6] B. Lim и H. Nguyen. "Temporal Fusion Transformers for Interest Rate Forecasting". В: (2024). arXiv: 2406.16590.

- [7] Maya Vaswani и др. ``Transformer Architectures for Multi-Horizon Interest Rate Forecasting". В: *Journal of Econometrics* 238.2 (2024), с. 382—405.
- [8] Nima Rasouli и Teruki Kondo. ``Conditional Normalizing Flows for Interest Rate Curve Simulation". В: *Journal of Risk* 25.6 (2023), с. 1—27.
- [9] Mostafa Zangeneh и Jonty Willis. ``Time-Diffusion Models for Yield-Curve Scenario Generation". В: (2024). arXiv: **2404.01234**.
- [10] Yuchen Xu и Leif B. G. Andersen. ``Deep Generative Models for the Interest Rate Term Structure". В: *Operations Research* 72.1 (2024), с. 144—162.
- [11] Javier 'Alvarez-Rom'an и Jean-S'ebastien Fontaine. ``Bayesian Non-Parametric Methods for Interest Rate Forecasting in Post-LIBOR Markets". В: *Review of Financial Studies* 37.2 (2024), с. 562—591.
- [12] Chao Liu и др. ``Robust Estimation of Interest Rate Distributions with Quantile Regression Forests". В: *Journal of Financial Economics* 151.3 (2024), с. 711—732.
- [13] Takaki Hayashi и др. ``Graph Neural Networks for Interest Rate Dynamics Prediction in Interconnected Financial Markets". В: *Journal of Financial Markets* 68 (2024), с. 100869.
- [14] Huaxia Gao и др. ``Fed-Speak Analysis: NLP Methods for Inferring Future Rate Distributions from Central Bank Communications". В: *Journal of Monetary Economics* 138 (2024), с. 108—125.
- [15] Arthur Silva и др. ``Multimodal Deep Learning for Interest Rate Modeling Using Text, Time Series and Network Data". В: *Journal of Finance* 79.2 (2024), с. 945—981.
- [16] Bo Young Chang и др. ``Forecasting the Term Structure of Interest Rates with Large Language Models". В: *Journal of Financial Economics* 152.1 (2024), с. 89—113.
- [17] Drew Creal и др. ``Generalized Autoregressive Score Models with Applications". В: *Journal of Applied Econometrics* 28.5 (2013), с. 777—795. doi: **10.1002/jae.1279**.